



电子科技大学

University of Electronic Science and Technology of China

# Tackling Domain Shifts in Person Re-Identification: A Survey and Analysis

—— 应对行人重识别中的域偏移：综述与分析

汇报人

2025年6月

# 目录 CONTENTS



## 第一章 前言



## 第二章 研究背景



## 第三章 研究目标与本文贡献



## 第四章 研究内容



## 第五章 实验评估



## 第六章 未来研究方向与总结




前

第一章

言

## 1. 什么是 Person Re-Identification (ReID) (行人重识别)?



### 定义:

行人重识别 (Person re-identification, 简称Re-ID) 也称行人再识别, 是利用计算机视觉技术判断图像或者视频序列中是否存在特定行人的技术。

### 任务目标:

在非重叠摄像头视角下, 对同一行人进行匹配和识别。

### 通俗来讲:

一个区域有多个摄像头拍摄视频序列, ReID的要求对一个摄像头下感兴趣的行人, 检索到该行人在其他摄像头下出现的所有图片。

### 2.论文中的提出的域偏移问题是什么？

#### ➤ 当前针对ReID研究的假设与局限

多数 ReID 方法在 标准数据集上进行训练与测试。这些数据集假设数据来自固定场景、摄像头角度、光照条件，在训练过程中数据分布固定且静止，然而忽视了真实世界中频繁发生的 **数据分布变化 (Domain Shift)** 问题。

#### ➤ 引出核心问题：Domain Shift (域偏移)

**域偏移指的是：**训练数据与测试数据在分布上存在显著差异，导致模型性能下降。



## 第二章 研究背景

Person Re-Identification (ReID) 旨在跨越非重叠摄像头视角，对同一个人不同场景下的图像进行匹配。该任务在视频监控、安全防范、人机交互等应用中扮演着关键角色。虽然在标准数据集上取得了显著进展，但这些成果大多建立在训练与测试数据分布一致的理想条件下，而非真实世界中经常面临的挑战。

其中最关键的挑战之一是：

### **Domain Shift (域偏移)**

这指的是训练数据和测试数据之间的分布差异，可能由不同地点、光照条件、摄像头角度等引起，从而导致ReID系统在新环境下性能大幅下降。

然而，**现有研究主要关注：**

➤ **Cross-dataset Domain Shift (跨数据集偏移)**：不同数据集之间的视觉/场景差异；

**而忽略了：**

➤ **Attribute Domain Shift (属性偏移)**：如衣物更换、体型变化、步态差异等个人外观变化。



### 第三章

## 研究目标与本文贡献



### 1.重新定义ReID中的“域偏移”概念

将传统意义上的**跨数据集域偏移** (cross-dataset domain shift) **扩展为包含属性域偏移** (attribute domain shift), 后者涵盖了人物外观随时间变化 (如换衣、体型、步态等) 所导致的识别难度上升。这种重定义, 更符合现实部署环境中ReID系统所面临的挑战。

### 2.结构化综述三大跨域ReID研究方向

- 无监督领域自适应ReID (UDA-ReID)
- 领域泛化ReID (DG-ReID)
- 终身ReID (Lifelong ReID, LReID)

### 3.在公平实验设置下, 全面评估现有LReID方法(不换衣)

在**不涉及衣物变化的标准ReID设置**下, 本文设计了统一的实验流程, 旨在评估当前LReID方法在应对跨数据集域偏移时的实际能力。主要目标包括:

评估已见域抗遗忘能力以及未见域泛化能力

### 4.首次提出LCCReID评估基准, 系统研究属性域偏移下的持续学习问题(换衣)

作者提出了一个更具挑战性和实际意义的评估设置——(LCCReID)。

- 构建了**包含多个换衣ReID数据集的训练/测试流程**;
- 将方法性能划分为“已见域抗遗忘能力”和“未见域泛化能力”两大类进行对比;
- 发现所有现有方法在衣物变化条件下的性能均显著下降, 验证了该任务的重要性和挑战性

01

首次对Person ReID中的领域偏移问题进行了系统综述，重点关注终身ReID (LReID) 场景

02

总结了现有应对跨数据集域偏移的主流解决方案，涵盖UDA-ReID、DG-ReID和LReID三大类

03

并在公平实验设置下（无换衣）比较了LReID方法的优劣，并提出并定义了“属性域偏移”这一更贴近现实的ReID问题（衣物变化），首次评估LReID方法在衣物变化场景下的表现。

04

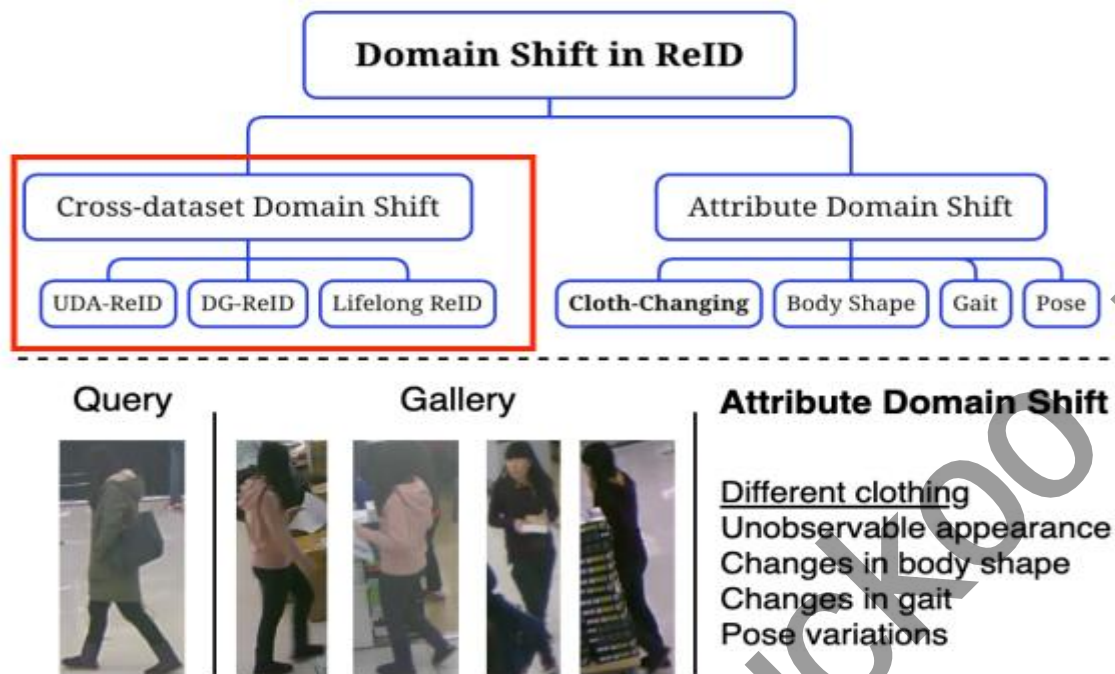
提出未来研究方向，推动构建更具适应性、鲁棒性与持续学习能力的跨域ReID系统



## 第四章 研究内容

## 第四章 | 研究内容

### 1. 方法综述



本文首先对现有的跨域ReID方法进行了系统性综述，聚焦于三大主流子任务：

1. **无监督领域自适应ReID** (Unsupervised Domain Adaptation ReID, UDA-ReID)
2. **领域泛化ReID** (Domain Generalizable ReID, DG-ReID)
3. **终身ReID** (Lifelong ReID, LReID)

# 1.无监督领域自适应 ReID (UDA-ReID)

## 任务定义:

利用标注的源域数据，提升模型在未标注的目标域数据上的表现。假设训练阶段可以同时访问源域和目标域数据（目标域无标签）。

主流方法可分为三类:

方法	伪标签估计 (Pseudo Label Estimation)	中层特征对齐 (Mid-Level Feature Alignment)	GAN 风格迁移 (GAN-based Style Transfer)
定义	利用聚类算法在目标域中产生伪标签，并将其用于监督训练过程。	对源域与目标域之间的中层特征表示进行对齐，从而缓解域差异	通过GAN将源域图像转换为目标域风格，使源域样本在视觉上与目标域更接近，从而弥合域间外观差异
涉及方法	MMT、DLU、SGLR、HC-GCN、Self-paced Refinement、Camera-normalized Clustering	Attribute-Semantic + Identity Feature Joint Learning、Self-similarity Grouping、Memory ReconsolidationAttention-guided Transfer	Pose Disentanglement GAN、Factor-wise Transfer GAN、DG-Net、TC-GAN + DFE-Net

2.领域泛化 ReID (DG-ReID)



任务定义:

在只使用一个或多个标注源域数据的条件下，训练模型能够直接泛化至未知目标域，不访问任何目标域样本。

主流方法可分为三类:

方法	元学习 (Meta-Learning)	风格混合 (Style Mixing)	伪标签策略 (Pseudo-label-based DG)
定义	模拟测试过程中的域间分布变化，训练阶段以“域”为单位进行任务划分，从而提升模型在未见域上的泛化能力	在特征空间中进行风格混合，以模拟跨域特征扰动并提升鲁棒性	采用伪标签生成机制辅助DG训练（多为无监督或半监督）
涉及方法	Curriculum Meta Learning：以由浅入深的方式逐步增加训练任务的难度	Style Memory Bank：维护多个域的风格存储，并在训练中进行插值混合；	Multi-network Label Generation
	Domain-aware Meta Learner：通过任务采样反映不同风格差异，学习域间适应策略	Style Interleaving：将不同域特征风格交叉注入训练网络；	Confidence-aware Contrastive Loss：降低低置信度伪标签的训练权重，缓解标签噪声
		Feature-space Augmentation：作为隐式正则手段混合不同风格特征。	

## 2. 终身学习 ReID (LReID)

### 任务定义:

模型需在新域数据逐步、流式出现的条件下持续学习，同时保持对旧域的识别能力（抗遗忘），并保持对未来未知域的泛化能力。

主流方法可分为三类:

方法	知识蒸馏类方法 (Knowledge Distillation-based Methods)			数据重放类方法 (Data Rehearsal / Replay)	无监督终身学习方法 (Unsupervised LReID)
定义	通过设计特定的蒸馏机制，在不同学习阶段之间传递知识，防止灾难性遗忘。			存储部分旧域样本的特征或图像，在新阶段重放以辅助训练	在无标签情境下进行持续学习，更贴合数据隐私受限的实际应用场景
相关方法	Feature/Logit蒸馏	蒸馏损失设计	图结构蒸馏	GwF：通用重放框架；	UCR：无监督对比回放 + 图像相似度约束；
	LwF扩展； Patch-based蒸馏 (PKD)； Region-aware蒸馏 (RFL)；	PTKP：伪任务建模 + 特征分布约束； MRN loss：用于解决归一化层的域不稳定问题； AGD loss：保持结构几何一致性；	AKA：构建特征图传递历史知识； GAT-based Knowledge Transfer； RCD-based Ranking Distillation；	KRKC：动态记忆模型，支持双向知识迁移；  Auto-Weighted Embedding：使用自编码器重建旧任务嵌入，赋予不同样本不同保留权重。	LUDA：部署模型通过历史与当前之间关系保持一致性，适用于检索场景；  Color Prompting (CoP)：无需存储数据，通过颜色分布模拟旧域风格，适应隐私限制。





# 第五章 实验评估



## 第五章 | 实验评估

### 1.1 标准ReID任务（无衣物变化）——标准ReID中的抗遗忘性能评估

Dataset	Mode	Scale	#TrainIDs	#TestIDs
Market-1501 [81]	Seen	large	500 (751)	750
CUHK-SYSU [69]		mid	500 (942)	2900
DukeMTMC [82]		large	500 (702)	1110
MSMT17 [66]		large	500 (1041)	3060
CUHK03 [30]		mid	500 (767)	700
Viper [13]	Unseen	small	-	316
PRID [17]		small	-	649
GRID [39]		small	-	126
i-LIDS [27]		small	-	60
CUHK01 [29]		small	-	486
CUHK02 [28]		mid	-	239
SenseReID [80]		mid	-	1718
PRCC [71]	CC <sub>seen</sub>	mid	75 (150)	71
LTCC [52]		mid	75 (77)	75
DeepChange [70]		large	75 (450)	521
Real28 [63]	CC <sub>unseen</sub>	small	-	28
VC-Clothes [63]		mid	-	256
Celeb-light [21]		mid	-	200
LaST [56]		large	-	5806

Table 1. Statistics of Standard and Cloth-Changing datasets. The original number of training identities are put inside parentheses.

当模型逐步学习多个新的源域（每个域代表一个新阶段），是否会“遗忘”掉对早期学习过的数据域的识别能力？

将12个常用ReID数据集划分为：

共使用5个常见ReID数据集作为训练域(即 **Seen Domains**)：

Market-1501, DukeMTMC-ReID, CUHK-SYSU, MSMT17, CUHK03

每个训练阶段仅引入一个新的数据集

训练顺序为：Market-1501 → Duke → CUHK-SYSU → MSMT17 → CUHK03。

在每个阶段结束后，对前面所有训练过的域进行测试，评估其性能下降情况。


## 1.1 标准ReID任务（无衣物变化）结果——标准ReID中的抗遗忘性能评估

Method	Venue	Market-1501		CUHK-SYSU		DukeMTMC		MSMT17		CUHK03		Avg. Seen		Avg. Unseen	
		mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	$\bar{s}_{mAP}$	$\bar{s}_{R1}$	$\bar{u}_{mAP}$	$\bar{u}_{R1}$
SPD [62]	ICCV'19	35.6	61.2	61.7	63.4	27.6	47.1	5.2	15.5	42.2	44.3	34.4	46.4	40.4	36.6
LwF [35]	TPAMI'17	56.3	77.1	72.9	75.1	29.6	46.5	6.0	16.6	36.1	37.5	40.2	50.6	47.2	42.6
CRL [78]	CVPR'21	58.0	78.2	72.5	75.1	28.3	45.2	6.0	15.8	37.4	39.8	40.5	50.8	47.8	43.5
AKA [48]	CVPR'21	51.2	72.0	47.5	45.1	18.7	33.1	16.4	37.6	27.7	27.6	32.3	43.1	44.3	40.4
AKA <sup>†</sup> [48]	CVPR'21	58.1	77.4	62.5	64.8	28.7	45.2	6.1	16.2	38.7	40.4	40.8	50.8	47.6	42.6
AGD <sup>†</sup> [40]	CVPR'22	57.2	80.1	78.0	80.4	35.5	48.2	11.9	20.4	42.8	49.2	45.1	55.7	48.2	43.5
PTKP <sup>†</sup> [9]	AAAI'22	50.3	74.8	75.4	78.0	41.2	61.5	9.8	26.3	31.7	34.1	41.7	54.9	48.8	44.5
UCR <sup>†</sup> [1]	arXiv'22	59.3	82.7	78.3	80.0	34.2	46.7	10.1	19.4	40.5	45.9	44.5	54.5	46.4	43.8
PKD [60]	ACMMM'22	68.5	85.7	75.6	78.6	33.8	50.4	6.5	17.0	34.1	36.8	43.7	53.7	47.1	40.4
PKD <sup>†</sup> [60]	ACMMM'22	66.1	84.5	73.6	76.2	32.7	48.4	5.8	15.2	32.5	34.6	42.1	51.8	46.3	39.1
KRKC <sup>†</sup> [73]	AAAI'23	54.6	74.1	73.5	77.3	25.8	40.9	7.2	15.7	35.4	39.2	39.3	49.4	46.0	41.9
RFL [18]	PR'23	59.2	78.3	82.1	84.3	45.6	61.8	12.6	30.4	51.7	53.8	50.2	61.7	57.4	52.3
MEGE [50]	TPAMI'23	46.6	67.6	77.2	79.8	21.8	36.1	6.7	18.4	47.8	49.3	40.0	50.2	47.7	44.0
CKP [38]	NN'23	51.2	72.2	73.5	76.8	19.5	33.3	17.5	43.2	31.4	33.8	38.6	57.9	47.0	40.8

该表列出了主流 LReID 方法在训练完成后，在所有 seen domains 上的平均性能（抗遗忘能力），其中RFL以及AGD表现较好：

方法	平均 Seen mAP / R-1	评价
RFL	50.2 / 61.7	RFL 使用级联式知识蒸馏结构来保证特征的一致性，并采用加权蒸馏损失以防止由于旧知识重叠而导致当前领域泛化能力下降，从而能够有效缓解灾难性遗忘问题。
AGD	45.1 / 55.7	通过增强记忆样本本身，并以成对和交叉的方式进行知识蒸馏

## 1.1 标准ReID任务（无衣物变化）结果——标准ReID中的抗遗忘性能评估



论文图 5 显示了每个方法在训练阶段推进时，对早期域的性能保持曲线。图中每条线代表一个训练域，横轴表示训练阶段，纵轴表示mAP或R1。可以发现：

- ①所有方法在后期阶段对早期域的性能均有一定下降；
- ②最严重的为 SPD 方法（蓝线），从 80% 降至约 30%，说明该方法抗遗忘性差；
- ③相对平稳的包括 RFL、PKD、KRKC、UCR：
  - RFL（亮青线）保持最强 seen mAP，下降幅度小；
  - PKD、UCR 也展现良好的记忆保持能力



## 第五章 | 实验评估

### 1.2 标准ReID任务（无衣物变化）——Unseen-Domain Generalization（未见域泛化能力评估）

Dataset	Mode	Scale	#TrainIDs	#TestIDs
Market-1501 [81]	Seen	large	500 (751)	750
CUHK-SYSU [69]		mid	500 (942)	2900
DukeMTMC [82]		large	500 (702)	1110
MSMT17 [66]		large	500 (1041)	3060
CUHK03 [30]		mid	500 (767)	700
Viper [13]	Unseen	small	-	316
PRID [17]		small	-	649
GRID [39]		small	-	126
i-LIDS [27]		small	-	60
CUHK01 [29]		small	-	486
CUHK02 [28]		mid	-	239
SenseReID [80]		mid	-	1718
PRCC [71]	CC <sub>seen</sub>	mid	75 (150)	71
LTCC [52]		mid	75 (77)	75
DeepChange [70]		large	75 (450)	521
Real28 [63]	CC <sub>unseen</sub>	small	-	28
VC-Clothes [63]		mid	-	256
Celeb-light [21]		mid	-	200
LaST [56]		large	-	5806

Table 1. Statistics of Standard and Cloth-Changing datasets. The original number of training identities are put inside parentheses.

模型是否具备跨域泛化能力，即在没有目标域参与训练的前提下，依然能够识别全新域中的个体？

将12个常用ReID数据集划分为：

共使用5个常见ReID数据集作为训练域(即 **Seen Domains**)：

Market-1501, DukeMTMC-ReID, CUHK-SYSU, MSMT17, CUHK03

每个训练阶段仅引入一个新的数据集

训练顺序为：Market-1501 → Duke → CUHK-SYSU → MSMT17 → CUHK03。

选择 7 个模型从未见过的数据集用于测试泛化能力（未见域测试）：

Viper、PRID、GRID、i-LIDS、CUHK01、CUHK02  
SenseReID

# 1.2 标准ReID任务（无衣物变化）——Unseen-Domain Generalization（未见域泛化能力评估）




Method	Venue	Market-1501		CUHK-SYSU		DukeMTMC		MSMT17		CUHK03		Avg. Seen		Avg. Unseen	
		mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	mAP	R-1	$\bar{s}_{mAP}$	$\bar{s}_{R1}$	$\bar{u}_{mAP}$	$\bar{u}_{R1}$
SPD [62]	ICCV'19	35.6	61.2	61.7	63.4	27.6	47.1	5.2	15.5	42.2	44.3	34.4	46.4	40.4	36.6
LwF [35]	TPAMI'17	56.3	77.1	72.9	75.1	29.6	46.5	6.0	16.6	36.1	37.5	40.2	50.6	47.2	42.6
CRL [78]	CVPR'21	58.0	78.2	72.5	75.1	28.3	45.2	6.0	15.8	37.4	39.8	40.5	50.8	47.8	43.5
AKA [48]	CVPR'21	51.2	72.0	47.5	45.1	18.7	33.1	16.4	37.6	27.7	27.6	32.3	43.1	44.3	40.4
AKA <sup>†</sup> [48]	CVPR'21	58.1	77.4	62.5	64.8	28.7	45.2	6.1	16.2	38.7	40.4	40.8	50.8	47.6	42.6
AGD <sup>†</sup> [40]	CVPR'22	57.2	80.1	78.0	80.4	35.5	48.2	11.9	20.4	42.8	49.2	45.1	55.7	48.2	43.5
PTKP <sup>†</sup> [9]	AAAI'22	50.3	74.8	75.4	78.0	41.2	61.5	9.8	26.3	31.7	34.1	41.7	54.9	48.8	44.5
UCR <sup>†</sup> [1]	arXiv'22	59.3	82.7	78.3	80.0	34.2	46.7	10.1	19.4	40.5	45.9	44.5	54.5	46.4	43.8
PKD [60]	ACMMM'22	68.5	85.7	75.6	78.6	33.8	50.4	6.5	17.0	34.1	36.8	43.7	53.7	47.1	40.4
PKD <sup>†</sup> [60]	ACMMM'22	66.1	84.5	73.6	76.2	32.7	48.4	5.8	15.2	32.5	34.6	42.1	51.8	46.3	39.1
KRKC <sup>†</sup> [73]	AAAI'23	54.6	74.1	73.5	77.3	25.8	40.9	7.2	15.7	35.4	39.2	39.3	49.4	46.0	41.9
RFL [18]	PR'23	59.2	78.3	82.1	84.3	45.6	61.8	12.6	30.4	51.7	53.8	50.2	61.7	57.4	52.3
MEGE [50]	TPAMI'23	46.6	67.6	77.2	79.8	21.8	36.1	6.7	18.4	47.8	49.3	40.0	50.2	47.7	44.0
CKP [38]	NN'23	51.2	72.2	73.5	76.8	19.5	33.3	17.5	43.2	31.4	33.8	38.6	57.9	47.0	40.8

该表列出了列出了每种方法在“未见域集合”上的平均性能

方法	平均 Seen mAP / R-1	评价
RFL	57.4 / 52.3	RFL 利用特征洞察力（Feature Perspicacity）来生成多样性特征并提取判别性特征，在学习具有代表性的 ReID 特征方面表现出色。
PTKP	48.8 / 44.5	采用一种机制，将新任务的特征映射到旧任务的特征空间中，并引入任务特定的领域一致性损失，从而增强其在未知领域中的泛化能力

## 1.2 标准ReID任务（无衣物变化）——Unseen-Domain Generalization（未见域泛化能力评估）



1. RFL 在 Unseen mAP 和 R1 上均排名第一：

2. PTKP 和 AGD 表现相对接近，优于 PKD 和 AKA：

3. PKD 表现相对略低：

4. 泛化能力随阶段略有上升，但有限：

原因可能是模型越训练越专注于新加入的域，造成“对旧任务记住了，但未见任务仍然陌生”



## 第五章 | 实验评估

### 2.1 换衣ReID任务 (LCCReID基准) ——换衣场景下的抗遗忘性能评估

Dataset	Mode	Scale	#TrainIDs	#TestIDs
Market-1501 [81]	Seen	large	500 (751)	750
CUHK-SYSU [69]		mid	500 (942)	2900
DukeMTMC [82]		large	500 (702)	1110
MSMT17 [66]		large	500 (1041)	3060
CUHK03 [30]		mid	500 (767)	700
Viper [13]	Unseen	small	-	316
PRID [17]		small	-	649
GRID [39]		small	-	126
i-LIDS [27]		small	-	60
CUHK01 [29]		small	-	486
CUHK02 [28]		mid	-	239
SenseReID [80]		mid	-	1718
PRCC [71]	CC <sub>seen</sub>	mid	75 (150)	71
LTCC [52]		mid	75 (77)	75
DeepChange [70]		large	75 (450)	521
Real28 [63]	CC <sub>unseen</sub>	small	-	28
VC-Clothes [63]		mid	-	256
Celeb-light [21]		mid	-	200
LaST [56]		large	-	5806

Table 1. Statistics of Standard and Cloth-Changing datasets. The original number of training identities are put inside parentheses.

模型在逐步接收多个换衣数据域进行终身训练后，是否还能保留对早期训练数据的识别能力？

训练数据包括三个 衣物变化的ReID数据集，以阶段性方式输入模型,每个数据集中采样 75个身份进行训练，遵循“终身学习”的数据到达顺序（PRCC → LTCC → DeepChange）。

在每个阶段结束后，对前面所有训练过的域进行测试，评估其性能下降情况。

2.1 换衣ReID任务 (LCCReID基准) ——换衣场景下的抗遗忘性能评估

Method	Venue	PRCC		LTCC		DeepChange		Avg. Seen		Avg. Unseen	
		mAP	R-1	mAP	R-1	mAP	R-1	$\bar{s}_{mAP}$	$\bar{s}_{R1}$	$\bar{u}_{mAP}$	$\bar{u}_{R1}$
AKA [48]	CVPR'21	31.2	35.6	10.1	13.4	8.6	31.5	16.6	26.8	14.5	30.1
AGD [40]	CVPR'22	32.0	36.7	10.7	13.9	8.8	32.0	17.2	27.5	16.2	34.5
PTKP [9]	AAAI'22	33.1	37.9	11.8	14.7	9.1	34.9	18.0	29.2	15.8	33.0
UCR [1]	arXiv'22	34.6	38.2	12.3	15.0	8.9	34.8	18.6	29.3	16.1	34.9
PKD [60]	ACMMM'22	35.4	39.1	12.0	14.9	9.3	35.3	18.9	29.8	17.8	36.2
KRKC [73]	AAAI'23	33.2	37.4	11.3	13.9	8.9	33.8	17.8	28.4	15.3	33.7

Table 3. Seen-domain Anti-Forgetting evaluation on CCR<sub>ReID</sub> datasets. We produce results of all six method using their released codes. Best results are shown in **bold**, while second-to-best results are underlined.

所有方法性能显著低于无衣物变化场景（对比表2中50%+水平），说明衣物变化严重影响记忆保持。

方法	平均 Seen mAP / R-1	评价
PKD	18.9 / 29.8	基于图像补丁（patch-based）的策略。通过补丁提取的局部特征能够包含来自人脸或身体部位的衣物无关特征。
UCR	18.6 / 29.3	虽为无监督方法，但在有标签数据下仍表现良好，性能仅略低于 PKD，具有较强知识保持能力。

其他方法依赖全局外观表示，在换装影响下性能显著下降，易受灾难性遗忘影响



## 2.1 换衣ReID任务 (LCCReID基准) ——换衣场景下的抗遗忘性能评估




Figure 6. Tendency of (1) anti-forgetting performance on the first seen domain during incremental training process (the first two plots), and (2) generalization performance on unseen domains (the last two plots) on **CCReID**.

1. 所有方法性能下降显著；
2. AGD 表现最差，从约56% mAP 下降到31%，R1 也下降 20+百分点；
3. PKD 表现最好，在第3阶段依然保持最高 seen mAP 与 R1；UCR、AGD 次之，曲线下降速度较慢；PTKP、AKA 遗忘显著。

## 第五章 | 实验评估

### 2.2 换衣ReID任务 (LCCReID基准) ——换衣场景下的未见域泛化能力评估 (CCunseen)

Dataset	Mode	Scale	#TrainIDs	#TestIDs
Market-1501 [81]	Seen	large	500 (751)	750
CUHK-SYSU [69]		mid	500 (942)	2900
DukeMTMC [82]		large	500 (702)	1110
MSMT17 [66]		large	500 (1041)	3060
CUHK03 [30]		mid	500 (767)	700
Viper [13]	Unseen	small	-	316
PRID [17]		small	-	649
GRID [39]		small	-	126
i-LIDS [27]		small	-	60
CUHK01 [29]		small	-	486
CUHK02 [28]		mid	-	239
SenseReID [80]		mid	-	1718
PRCC [71]	CC <sub>seen</sub>	mid	75 (150)	71
LTCC [52]		mid	75 (77)	75
DeepChange [70]		large	75 (450)	521
Real28 [63]	CC <sub>unseen</sub>	small	-	28
VC-Clothes [63]		mid	-	256
Celeb-light [21]		mid	-	200
LaST [56]		large	-	5806

Table 1. Statistics of Standard and Cloth-Changing datasets. The original number of training identities are put inside parentheses.

模型在训练过程中接触的是一系列衣物变化数据集 (PRCC、LTCC、DeepChange)，能否将学到的表示泛化到从未见过的、衣物变化更复杂的测试域中？

**训练集：**

训练数据包括三个 衣物变化的ReID数据集，以阶段性方式输入模型,每个数据集中采样 75个身份进行训练，遵循“终身学习”的数据到达顺序 (PRCC → LTCC → DeepChange)。

该测试集合并了 4 个公开的换衣ReID数据集 (训练中未见)：  
Real28、VC-Clothes、Celeb-reID-light、LaST

→ 合计 6920 个身份，151,285 张图像

→ 全部数据未参与训练，仅用于泛化测试。

## 2.2 换衣ReID任务 (LCCReID基准) ——换衣场景下的未见域泛化能力评估 (CCunseen)

Method	Venue	PRCC		LTCC		DeepChange		Avg. Seen		Avg. Unseen	
		mAP	R-1	mAP	R-1	mAP	R-1	$\bar{s}_{mAP}$	$\bar{s}_{R1}$	$\bar{u}_{mAP}$	$\bar{u}_{R1}$
AKA [48]	CVPR'21	31.2	35.6	10.1	13.4	8.6	31.5	16.6	26.8	14.5	30.1
AGD [40]	CVPR'22	32.0	36.7	10.7	13.9	8.8	32.0	17.2	27.5	16.2	34.5
PTKP [9]	AAAI'22	33.1	37.9	11.8	14.7	9.1	34.9	18.0	29.2	15.8	33.0
UCR [1]	arXiv'22	<u>34.6</u>	<u>38.2</u>	<b>12.3</b>	<b>15.0</b>	8.9	34.8	<u>18.6</u>	<u>29.3</u>	16.1	<u>34.9</u>
PKD [60]	ACMMM'22	<b>35.4</b>	<b>39.1</b>	<u>12.0</u>	<u>14.9</u>	<b>9.3</b>	<b>35.3</b>	<b>18.9</b>	<b>29.8</b>	<b>17.8</b>	<b>36.2</b>
KRKC [73]	AAAI'23	33.2	37.4	11.3	13.9	8.9	33.8	17.8	28.4	15.3	33.7

Table 3. Seen-domain Anti-Forgetting evaluation on **CCReID** datasets. We produce results of all six method using their released codes. Best results are shown in **bold**, while second-to-best results are underlined.

所有方法性能整体不佳，mAP均低于 18%，R1不超过 37%

方法	平均 Seen mAP / R-1	评价
PKD	17.8 / 36.2	基于 patch 的特征提取策略，有效提升泛化能力，表现最优。
AGD	<b>16.2</b> / 34.5	平均 mAP 上取得了第二优的表现，归因于采用 pair-wise 和 cross-wise 特征排序，从而使得在一定程度上减少衣物变化下的类内差异，表现较好。

总体来看，目前已有的 LReID 方法并不是为换装下的 CCreID 场景设计的，从所有方法在平均 mAP 和平均 Rank-1 准确率上普遍较低，且差异不大的表现可以明显看出这一点。

## 2.2 换衣ReID任务 (LCCReID基准) ——换衣场景下的未见域泛化能力评估 (CCUnseen)




Figure 6. Tendency of (1) anti-forgetting performance on the first seen domain during incremental training process (the first two plots), and (2) generalization performance on unseen domains (the last two plots) on **CCReID**.

- 1.整体水平很低：mAP 不超过18%，R1 不超过36%；所有方法表现较差，说明换衣+未见环境的挑战极大；
- 2.PKD 最优，UCR、AGD 次之；AKA 明显滞后，说明其全局图蒸馏结构对衣物变化鲁棒性差。





## 第六章

# 未来研究方向与总结

研究方向	详细内容以及策略
1. Addressing Attribute Domain Shift (应对属性域偏移)	(1) Clothing-guided adaptation techniques: 专注于对齐源域与目标域之间的衣物属性, 强调衣物无关知识的迁移, 并减弱其他跨域因素的影响; (2) Explicitly capturing cloth-invariant cues from body shape or gait, 并在增量学习中重放这些知识; (3) Leveraging generative models for cloth synthesis or augmentation, 模拟目标域中衣物的分布。
2.Improving Generalizability of LReID Methods (提升LReID方法的泛化能力)	这是另一个需要解决的重要问题。 如第2.3节所示, 目前大多数现有方法仅显式地解决灾难性遗忘问题。 从表2和表3可看出, 大多数方法在泛化性能方面仍有较大提升空间。
3.Efficient Knowledge Preservation and Transfer Methods for LReID (高效的LReID知识保持与迁移方法)	未来应开发那些不依赖数据存储与重放的LReID知识保持与迁移方法。这类方法不仅可以提高效率, 同时也能减少在真实部署中对内存的需求。
4.Investigation on Different Training Orders of Lifelong ReID (终身ReID中不同训练顺序的探索)	未来应探讨适应某些域的顺序对整体模型性能的影响。例如, 可以根据某些源域与目标域之间的相关性或相似性来优先处理特定的“seen domain”, 以提升在“unseen domain”上的泛化能力。
5.Developing Hyperparameter Tuning Strategies tailored for tackling domain shift (为应对域偏移而定制的超参数调节策略)	这包括基于当前域的特性, 动态调整超参数的技术, 使模型更好地适应不断变化的环境。
6.Exploration of Lifelong ReID in Multimodal Settings (多模态场景下终身ReID的探索)	当存在视觉、文本等多种模态信息时, 未来研究可探讨如何使终身ReID模型能够有效利用和适应多样的模态, 以提升ReID性能并增强其鲁棒性。

- ①本文首次综述了**行人重识别 (Person ReID) 中应对域偏移 (domain shift)** 问题的研究。
- ②探讨了**跨数据集ReID的设置**，包括无监督域自适应 (UDA-ReID) 和域泛化 (DG-ReID) 以及终身学习ReID (LReID) ，并对终身学习ReID (LReID) 进行了深入分析。
- ③在LReID中，**基于知识蒸馏和数据重放的方法在保持知识与防止灾难性遗忘方面**仍具有竞争力。
- ④然而，目前尚未有方法专门用于提升LReID模型的泛化能力。
- ⑤首次引入了**换装场景下的LReID新任务**，该任务同时涉及数据与属性的变化。
- ⑥本文对现有LReID方法在**标准场景和换装场景下进行了全面评估**。

作者认为：本综述和分析将为未来域偏移背景下的ReID研究提供重要的指导。



电子科技大学

University of Electronic Science and Technology of China

感谢老师的悉心指导

THANK YOU!

汇报人

2025年6月